



Transformacja Energetyczna Polski (2015–2025)

Raport analityczny na bazie platformy ENTSO-E

Metadane	Opis
Uczelnia	Uniwersytet WSB Merito Chorzów
Przedmiot	Analiza i wizualizacja danych – Pandas, DataFrame
Zespół	Dawid Hetmańczyk (126674), Bartosz Bugla (180737)
Zakres czasowy	2015–2025 (PL); 2020–2025 (DE, FR, ES, BG, SE)
Źródło danych	ENTSO-E Transparency Platform (API)

Spis treści

1. Opis problemu	3
Problem badawczy	3
Kontekst biznesowy	3
Cele analityczne	3
2. Opis zbioru danych	4
Źródło	4
Typy danych z API	4
Liczba rekordów i zakres czasowy	4
Opis kolumn (Polska — wybrane pola)	4
Statystyki opisowe (Polska, pełne lata 2015–2025)	5
3. Pre-processing	6
Pipeline transformacji danych	6
Kroki czyszczenia danych	6
Outliery	6
4. Analiza statystyczna	7
4.1 Rozkłady i test normalności (Shapiro-Wilk)	7
4.2 Test porównawczy: weekend vs dzień roboczy	8
4.3 Macierz korelacji Pearsona	9
4.4 Test stacjonarności (Augmented Dickey-Fuller)	10
4.5 Średnia roczna ceny day-ahead [EUR/MWh]	10
5. Analiza zaawansowana	11
5.1 Apache Spark — uzasadnienie braku zastosowania	11
5.2 Szeregi czasowe — dekompozycja sezonowa	11
5.3 Predykcja i uczenie maszynowe	13
6. Polska na tle Unii Europejskiej	13
Transformacja miksu energetycznego	15
7. Podsumowanie i wnioski	17
1. Transformacja miksu postępuje, lecz węgiel dominuje	17
2. Rozwój OZE generuje nowe zjawiska cenowe	17
3. Ceny reagują na wydarzenia makro i regulacyjne	17
4. Zapotrzebowanie ma silną strukturę kalendarzową	17
5. Polska na tle UE: konwergencja po 2020	17

1. Opis problemu

Problem badawczy

Jak w latach 2015–2025 ewoluowała polska energetyka pod względem struktury wytwarzania, dynamiki cen rynku day-ahead oraz wzorców zapotrzebowania — i jak Polska wypada na tle wybranych krajów Unii Europejskiej (Niemcy, Francja, Hiszpania, Bułgaria, Szwecja)?

Kontekst biznesowy

Polska pozostaje jednym z najbardziej węglozależnych krajów UE, jednocześnie przeżywając gwałtowny rozwój odnawialnych źródeł energii (OZE), w szczególności fotowoltaiki i energetyki wiatrowej. W analizowanym okresie na rynek wpłynęły trzy istotne czynniki makro:

1. **Integracja rynkowa z UE** — market coupling (XI 2019) połączył polski rynek z europejską pulą cenową.
2. **Pandemia COVID-19** (2020) — gwałtowny spadek zapotrzebowania przemysłowego i cen energii.
3. **Kryzys energetyczny** (2021–2022) — wzrost cen gazu i uprawnień do emisji CO₂.

Od 2023 r. na polskim rynku pojawia się zjawisko ujemnych cen day-ahead — sygnał nadprodukcji OZE (głównie PV) w godzinach szczytu słonecznego oraz potrzeby elastyczności systemu (magazyny energii, demand response, modernizacja bloków konwencjonalnych).

Cele analityczne

Na podstawie kodu w _analysis.ipynb zdefiniowano pięć celów badawczych:

4. Zmierzyć transformację miksu energetycznego (udział węgla, OZE, gazu).
5. Zidentyfikować determinanty i anomalie cen (ujemne ceny, sezonowość PV, wydarzenia makro).
6. Porównać Polskę z krajami referencyjnymi UE pod kątem cen, OZE i zapotrzebowania.
7. Rozłożyć szereg zapotrzebowania na składowe: trend, sezonowość i reszty (anomalie).
8. Statystycznie zweryfikować hipotezę o niższym zapotrzebowaniu w weekendy i dni świąteczne.

2. Opis zbioru danych

Źródło

Dane pochodzą z ENTSO-E Transparency Platform — oficjalnego źródła informacji o rynku energii w Europie. Pobieranie realizowane jest przez bibliotekę entsoe-py (EntsoePandasClient) w notebooku _etl.ipynb, z kluczem API przechowywanym w pliku .env.

Typy danych z API

Zapytanie API	Zmienna	Jednostka
query_generation	Produkcja wg źródeł	MW
query_wind_and_solar_forecast	Prognozy wiatru i słońca	MW
query_load	Rzeczywiste obciążenie sieci	MW
query_load_forecast	Prognozowane obciążenie	MW
query_day_ahead_prices	Cena rynku day-ahead	EUR/MWh

Liczba rekordów i zakres czasowy

Dane mają rozdzielczość godzinową po transformacji (resample("h").mean()).

Kraj	Plik CSV	Rekordy	Kolumny	Okres
Polska (PL)	energy_PL_...csv	96 433	19	2015–2025
Niemcy (DE)	energy_DE_...csv	52 608	20	2020–2025
Francja (FR)	energy_FR_...csv	52 609	17	2020–2025
Hiszpania (ES)	energy_ES_...csv	52 609	25	2020–2025
Bułgaria (BG)	energy_BG_...csv	52 609	17	2019–2025
Szwecja (SE)	energy_SE_...csv	52 608	12	2020–2025

Łącznie: ~359 476 rekordów godzinowych w sześciu zbiorach. Po walidacji kompletności (lata z ≥8000 godzin) zbiór analityczny dla Polski obejmuje 96 432 wiersze (lata 2015–2025).

Opis kolumn (Polska — wybrane pola)

Kolumna	Typ	Opis
time	datetime64[ns, tz]	Indeks czasowy (UTC → Europe/Warsaw)
Actual Load	float64	Rzeczywiste zapotrzebowanie sieci [MW]
Price DA	float64	Cena rynku day-ahead [EUR/MWh]
Fossil Hard coal	float64	Produkcja z węgla kamiennego [MW]
Fossil Brown coal/Lignite	float64	Produkcja z węgla brunatnego [MW]
Fossil Gas	float64	Produkcja z gazu ziemnego [MW]

Kolumna	Typ	Opis
Wind Onshore	float64	Energia wiatrowa lądowa [MW]
Solar	float64	Fotowoltaika [MW]
renewable	float64	Pole obliczone — suma kolumn OZE [MW]

Zestaw kolumn różni się między krajami w zależności od danych zwracanych przez ENTSO-E (np. Niemcy zawierają Nuclear i Wind Offshore; Szwecja — 12 kolumn).

Statystyki opisowe (Polska, pełne lata 2015–2025)

Zmienna	Średnia	Minimum	Maksimum
Actual Load	19 023,6 MW	0	28 303,9 MW
Price DA	112,4 EUR/MWh	-133,0	1 035,8
Solar	678,9 MW	0	13 682,3 MW
Wind Onshore	1 872,5 MW	8,2	8 897,4 MW
renewable (OZE)	2 978,9 MW	145,5	16 192,2 MW

W zbiorze analitycznym brak wartości pustych — count = 96 432 dla każdej kolumny numerycznej.

3. Pre-processing

Pipeline transformacji danych

Przygotowanie danych realizowane jest w `_data_transformation.ipynb` funkcją `handle_dataset()`, według sekwencji: `raw/*.csv` → `handle_time_column` (UTC → Europe/Warsaw) → `resample_to_hours` → `normalize_energy_columns` → `handle_empty_rows` (`ffill` + `bfill`) → `add_renewable_field` → `datasets/energy_*.csv`.

Kroki czyszczenia danych

- **Parsowanie i strefa czasowa** — kolumna `time` parsowana do UTC, konwertowana do Europe/Warsaw i ustawiana jako indeks. Ujednolicenie stref jest kluczowe dla porównań międzykrajowych i profilu dobowego.
- **Resampling godzinowy** — `resample("h").mean()` ujednolica rozdzielczość; API ENTSO-E zwraca dane w różnych rozdzielczościach.
- **Normalizacja kolumn** — usunięcie kolumn `Consumption/Forecast` i duplikatów (.1, .2); heurystyka OZE odrzucająca prognozy; grupowanie duplikatów nazw.
- **Braki (missing values)** — identyfikacja pustych kolumn (raport diagnostyczny) oraz uzupełnianie `ffill()` + `bfill()`. W zbiorze PL po transformacji: 0 braków.
- **Typy danych** — kolumny numeryczne `float64`; indeks `DatetimeIndex` ze strefą czasową.
- **Walidacja** — filtrowanie lat z ≥ 8000 godzin (wykluczenie niekompletnych lat kalendarzowych).

Outliery

W projekcie nie zastosowano mechanicznego usuwania wartości odstających (brak filtrów IQR, z-score, winsoryzacji). Anomalie identyfikowane są eksploracyjnie: reszty dekompozycji sezonowej, święta państwowe nakładane na szereg zapotrzebowania, rozkład godzinowy ujemnych cen DA oraz ekstremalne szczyty cen (do 1 035,8 EUR/MWh; skew = 1,21).

4. Analiza statystyczna


4.1 Rozkłady i test normalności (Shapiro-Wilk)

Przed testami porównawczymi zweryfikowano normalność rozkładów testem Shapiro-Wilka. Ze względu na limit testu stosowano próbkowanie $\min(5000, n)$, $\text{random_state}=42$.


Seria	n	Skośność	Kurtoza	Shapiro W	p-value	Wniosek
Dzień roboczy	68 880	-0,28	-0,72	0,9783	$5,5 \times 10^{-27}$	NIE normalny
Weekend	27 552	0,19	-0,38	0,9945	$6,8 \times 10^{-13}$	NIE normalny
Price DA	96 432	1,21	3,22	0,9248	$1,5 \times 10^{-44}$	NIE normalny
Actual Load	96 432	0,02	-0,85	0,9825	$2,1 \times 10^{-24}$	NIE normalny

Wniosek: rozkłady cen i zapotrzebowania istotnie odbiegają od normalnego. Ceny wykazują silną prawoskośność ($\text{skew} = 1,21$) i leptokurtozę ($\text{kurtosis} = 3,22$) — typowe dla rynków energii z epizodami ekstremalnych cen. Wymusza to metody nieparametryczne lub transformację (np. log).

Rozkłady cen i zapotrzebowania (histogramy)



Rys. 1. Histogramy i rozkłady ceny day-ahead oraz zapotrzebowania.



Rys. 2. Rozrzut cen day-ahead w ujęciu rocznym — wartości skrajne i ujemne (od 2023).


4.2 Test porównawczy: weekend vs dzień roboczy

H₀: brak różnicy w średnim zapotrzebowaniu między dniami roboczymi a weekendami. **H₁:** średnie zapotrzebowanie w dzień roboczy jest wyższe niż w weekend.

Miara	Dzień roboczy	Weekend	Różnica
Średnia zapotrzebowania	19 860 MW	16 932 MW	-14,7%
Test	Statystyka	p-value	Decyzja ($\alpha = 0,05$)
Mann-Whitney U (nieparam.)	U = 1 456 277 098	≈ 0	Odrzucenie H ₀
Welch t-test (uzupełniająco)	t = 161,28	≈ 0	Odrzucenie H ₀
Cohen's d (wielkość efektu)	d = 1,072	—	Duży efekt


Zapotrzebowanie w weekend jest statystycznie istotnie i merytorycznie znacząco niższe niż w dni robocze. Wielkość efektu (Cohen's d = 1,07) klasyfikowana jest jako duża.

Zapotrzebowanie: dzień roboczy vs weekend



Rys. 3. Boxplot oraz profil dobowy: dzień roboczy vs weekend.

Średnie zapotrzebowanie z 95% CI
Mann-Whitney $p = 0.00e+00$, Cohen's $d = 1.07$




Rys. 4. Średnie zapotrzebowanie z 95% przedziałami ufności (Mann-Whitney, Cohen's $d = 1,07$).

4.3 Macierz korelacji Pearsona

Obliczono macierz korelacji Pearsona dla 8 zmiennych zagregowanych (cena DA, zapotrzebowanie, wiatr, PV, węgiel kamienny, węgiel brunatny, gaz, OZE). Kluczowe zależności liniowe:

Para zmiennych	r	Interpretacja
Zapotrzebowanie ↔ Węgiel kamienny	+0,74	Silna korelacja dodatnia — węgiel pokrywa bazę
Zapotrzebowanie ↔ Węgiel brunatny	+0,58	Umiarkowana korelacja dodatnia
Słońce (PV) ↔ OZE	+0,73	PV dominuje w profilu OZE w Polsce
Wiatr ↔ OZE	+0,66	Wiatr jako drugi filar OZE
Węgiel kamienny ↔ OZE	-0,46	Substytucja źródeł w miksie
Węgiel brunatny ↔ OZE	-0,52	Substytucja źródeł w miksie
Cena DA ↔ OZE	-0,18	Więcej OZE wiąże się z niższymi cenami

Macierz korelacji Pearsona (najważniejsze zmienne)



Rys. 5. Macierz korelacji Pearsona zmiennych zagregowanych.


4.4 Test stacjonarności (Augmented Dickey-Fuller)

Na dziennej średniej zapotrzebowania (`resample("D").mean()`): statystyka ADF = $-5,19$, p-value = $9,36 \times 10^{-6}$ → odrzucenie hipotezy o niestacjonarności. Szereg dzienny zapotrzebowania jest stacjonarny, co stanowi warunek wstępny dla modeli klasy ARIMA.


4.5 Średnia roczna ceny day-ahead [EUR/MWh]

2015	2016	2017	2018	2019	2020	2021	2022	2023	2024	2025
26	27	135	223	212	47	87	167	112	96	104

Średnia roczna cena day-ahead w Polsce



Rys. 6. Średnia roczna cena day-ahead w Polsce (2015–2025) z zaznaczeniem okresów makro.



Rys. 7. Ujemne ceny day-ahead: liczba godzin wg roku oraz rozkład godzinowy (duck curve).

5. Analiza zaawansowana

5.1 Apache Spark — uzasadnienie braku zastosowania

W projekcie nie wykorzystano Apache Spark / PySpark. Cały pipeline analityczny opiera się na Pandas w środowisku Jupyter:

Aspekt	Uzasadnienie
Skala danych	~360 tys. rekordów godzinowych (6 krajów) — mieści się w pamięci RAM
Operacje	resample, groupby, merge — natywnie wspierane przez Pandas
ETL	Pobieranie w fragmentach 6-mies. z retry (3 próby, backoff 10/20/30 s)
Wydajność	Wystarczająca dla wolumenu projektu zaliczeniowego


Perspektywa skalowania: przy rozszerzeniu na 27 krajów UE × 15 lat × rozdzielczość 15-minutową (~50 mln rekordów) sensowne byłoby przejście na Spark, Dask lub Polars z partycjonowaniem danych.

5.2 Szeregi czasowe — dekompozycja sezonowa


Narzędzie: statsmodels.tsa.seasonal.seasonal_decompose, model addytywny. Dekompozycja roczna na dziennych średnich Actual Load 2015–2024 (period = 365) oraz tygodniowa dla 2023 (period = 7).

- **Trend:** wzrost zapotrzebowania do 2019, gwałtowny spadek w 2020 (COVID-19), odbicie 2021–2022, następnie stabilizacja.
- **Sezonowość roczna:** regularne fale — szczyty zimowe (ogrzewanie), spadki letnie.
- **Sezonowość tygodniowa:** systematycznie niższe obciążenie w weekendy.
- **Reszty (anomalie):** spadki w dni świąteczne (Wigilia, Nowy Rok, 1 i 3 maja, 11 listopada, Boże Narodzenie) — porównywalne z efektem weekendowym.

Dekompozycja szeregu czasowego — dzienne zapotrzebowanie (2015–2024)




Rys. 8. Dekompozycja addytywna dziennego zapotrzebowania: obserwowane, trend, sezonowość, reszty.



Rys. 9. Dzielne zapotrzebowanie 2024 z naniesionymi świętami państwowymi.

Profil zapotrzebowania: Wigilia vs 23.12 vs Średnia dla Grudnia



Rys. 10. Profil dobowy: Wigilia vs 23.12 vs średnia grudniowa.

5.3 Predykcja i uczenie maszynowe


W `_analysis.ipynb` nie zaimplementowano modeli predykcyjnych (brak `sklearn`, `ARIMA`, `Prophet`, `LSTM`). Potencjalne kierunki rozszerzenia:

9. SARIMA na Actual Load z lagami sezonowymi (dobowymi, tygodniowymi, rocznymi).
10. Model ML z cechami kalendarzowymi: `godzina`, `dzień_tygodnia`, `miesiąc`, `is_weekend`, `is_holiday`.
11. Prognoza cen DA z uwzględnieniem udziału OZE i zapotrzebowania.
12. Pipeline produkcyjny z Apache Spark przy skali wielomilionowej.

6. Polska na tle Unii Europejskiej


Porównanie sześciu krajów (PL, DE, FR, ES, BG, SE) w latach 2020–2024 obejmuje udział OZE, produkcję OZE [TWh], roczne zapotrzebowanie [TWh] oraz ceny day-ahead. Polska charakteryzuje się umiarkowanym udziałem OZE (vs Szwecja/Niemcy) oraz historycznie wyższymi cenami, z wyraźną konwergencją po 2020 r. PL konsumuje ~168 TWh rocznie, wobec DE ~479 TWh i FR ~442 TWh.

Udział OZE w całkowitej generacji (2020–2024)




Rys. 11. Udział OZE w całkowitej generacji (2020–2024).

Roczna produkcja energii z OZE (2020–2024)




Rys. 12. Roczna produkcja energii z OZE [TWh] (2020–2024).

Roczne zapotrzebowanie na energię (2020–2024)



Rys. 13. Roczne zapotrzebowanie na energię [TWh] (2020–2024).

Średnia roczna cena DA (2020–2024)




Rys. 14. Średnia roczna cena day-ahead w wybranych krajach UE.

Wspólny szok cenowy 2022 (kryzys energetyczny) oraz konwergencja cen w 2023–2024 są efektem integracji europejskiego rynku energii. Polska zbliża się cenowo do Niemiec i Francji, lecz strukturalnie pozostaje bardziej węglozależna niż Szwecja (wiatr + jądro) czy Francja (jądro + OZE).


Transformacja miksu energetycznego

Udział węgla w produkcji spadł z 86,5% (2015) do 56,2% (2024) i 52,1% (2025). Produkcja z węgla zmalała ze 128,3 TWh do ~89 TWh (–30%). Fotowoltaika osiągnęła 12,1% miksu w 2025 — wielokrotny wzrost względem ~0% w 2015.

Ewolucja miksu energetycznego Polski (2015–2025)



Rys. 15. Ewolucja miksu energetycznego Polski (udziały, 2015–2025).



Rys. 16. Trend produkcji z węgla oraz porównanie sezonowości 2015 vs 2024.

7. Podsumowanie i wnioski

1. Transformacja miksu postępuje, lecz węgiel dominuje

Udział węgla spadł z 86,5% (2015) do 52,1% (2025), a produkcja o ~30% (128,3 → ~89 TWh). Fotowoltaika osiągnęła 12,1% miksu. Transformacja jest widoczna, ale Polska pozostaje krajem węglowym w skali europejskiej.

2. Rozwój OZE generuje nowe zjawiska cenowe

Ujemne ceny day-ahead: 43 godziny (2023) → 197 (2024) → 310 (2025), głównie 10:00–15:00 (szczyt PV, duck curve). Minimum: -132,95 EUR/MWh. System wymaga magazynów energii, demand response i modernizacji bloków konwencjonalnych.

3. Ceny reagują na wydarzenia makro i regulacyjne

Średnia roczna: 26–27 EUR/MWh (2015–16) → szczyt 223 (2018) → 47 (2020, pandemia) → 167 (2022, kryzys) → stabilizacja ~100 (2023–25). Market coupling (XI 2019) natychmiast obniżył ceny; rozkład jest prawoskośny.

4. Zapotrzebowanie ma silną strukturę kalendarzową

Weekend: -14,7% vs dzień roboczy (19 860 vs 16 932 MW). Mann-Whitney U: $p \approx 0$, Cohen's $d = 1,07$ (duży efekt). Święta państwowe zachowują się jak długie weekendy — istotne dla operatora sieci (PSE), traderów i planowania rezerw mocy.

5. Polska na tle UE: konwergencja po 2020

Porównanie sześciu krajów (2020–2024) pokazuje wspólny szok cenowy 2022 i konwergencję 2023–2024. Polska zbliża się cenowo do Niemiec i Francji, lecz strukturalnie pozostaje bardziej węglozależna niż Szwecja czy Francja.